

# Sistem Rekomendasi Pengobatan Osteoarthritis Lutut Menggunakan Model VGG16 dan Decision Tree

1<sup>st</sup> Hanief Anwar Hayat

*Departemen Teknik Elektro dan Teknologi Informasi*

*Universitas Gadjah Mada*

Yogyakarta, Indonesia

[haniefanwarhayat@mail.uqm.ac.id](mailto:haniefanwarhayat@mail.uqm.ac.id)

## Pendahuluan

Osteoarthritis (OA) lutut adalah penyakit sendi degeneratif yang memengaruhi jutaan orang di seluruh dunia, menyebabkan nyeri, kekakuan, dan penurunan mobilitas, terutama pada populasi lanjut usia. Penyakit ini merupakan salah satu penyebab utama kecacatan dan penurunan kualitas hidup, dengan dampak signifikan pada aktivitas fisik dan beban layanan kesehatan [1]. Deteksi dini dan klasifikasi tingkat keparahan OA sangat penting untuk pengelolaan yang efektif, mencegah perkembangan penyakit yang parah, dan mengurangi kebutuhan akan penggantian lutut total (TKR).

Proyek ini bertujuan untuk mengembangkan sistem otomatis yang:

1. Mengklasifikasikan tingkat keparahan OA lutut dari gambar X-ray menggunakan model deep learning VGG16 berdasarkan skala Kellgren-Lawrence (KL) grade 0 (sehat) hingga 4 (parah).
2. Merekomendasikan strategi pengobatan yang dipersonalisasi berdasarkan tingkat keparahan, usia, dan indeks massa tubuh (BMI) pasien menggunakan decision tree berbasis aturan.

Sistem ini diimplementasikan di Google Colab, dengan dataset diunggah dari laptop, bertujuan untuk membantu dokter dalam diagnosis cepat dan pengambilan keputusan pengobatan yang lebih akurat.

## Tinjauan Pustaka

Penelitian terkini menunjukkan bahwa pembelajaran mesin, khususnya deep learning, telah mengubah pendekatan diagnosis OA lutut. Convolutional Neural Networks (CNN) seperti

VGG16, DenseNet, dan ResNet telah digunakan untuk mengklasifikasikan tingkat keparahan OA dari gambar X-ray dengan akurasi tinggi [2]. Pendekatan multimodal yang menggabungkan data radiografi dengan data klinis, seperti riwayat medis dan pemeriksaan fisik, telah meningkatkan prediksi progresi OA [3]. Sistem otomatis ini mengurangi waktu dan kesalahan dalam diagnosis manual, memberikan dukungan keputusan yang lebih efisien bagi dokter [4].

Studi juga menyoroti tantangan seperti ketidakseimbangan dataset, di mana jumlah gambar untuk setiap kelas KL bervariasi, yang dapat memengaruhi performa model [5]. Selain itu, meskipun skala KL adalah standar untuk menilai keparahan OA secara radiografis, keputusan pengobatan di klinik lebih bergantung pada gejala seperti nyeri dan keterbatasan fungsi, yang tidak sepenuhnya tercermin dalam KL grade [6].

## Metodologi

### 3.1 Pengumpulan Data

Dataset yang digunakan adalah "Kaggle Knee Osteoarthritis Dataset with Severity Grading," yang berisi gambar X-ray lutut dengan label KL grade 0 hingga 4, diambil dari Osteoarthritis Initiative (OAI) [7]. Dataset ini diunduh dari Kaggle dan diunggah sebagai file zip ke Google Colab untuk pemrosesan.

Tabel 3.1 *Kellgren-Lawrence Grading*

KL Grade	Deskripsi
0	Sehat, tidak ada tanda OA
1	Keraguan penyempitan ruang sendi,

	kemungkinan osteofit
2	Osteofit pasti, kemungkinan penyempitan ruang sendi
3	Osteofit multipel sedang, penyempitan ruang sendi pasti, sklerosis
4	Osteofit besar, penyempitan ruang sendi signifikan, deformitas tulang

### 3.2 Pra-pemrosesan Data

Gambar X-ray diproses menggunakan TensorFlow's ImageDataGenerator dengan langkah-langkah berikut:

- **Rescaling:** Nilai piksel diskalakan ke rentang [0, 1].
- **Pembagian Data:** Dataset dibagi menjadi set pelatihan (80%) dan validasi (20%).
- **Augmentasi Data:** Rotasi, zoom, dan flip horizontal diterapkan untuk meningkatkan keberagaman data pelatihan dan mencegah overfitting.

### 3.3 Sistem Pertama: Klasifikasi dengan VGG16

Model VGG16, yang telah dilatih sebelumnya pada ImageNet, digunakan untuk mengklasifikasikan gambar X-ray ke dalam lima kelas KL. Langkah-langkahnya:

- **Arsitektur Model:** Lapisan atas VGG16 dihapus, dan ditambahkan lapisan pooling rata-rata global serta lapisan dense dengan aktivasi softmax untuk klasifikasi 5 kelas.
- **Pembekuan Lapisan:** Lapisan dasar VGG16 dibekukan untuk mempertahankan bobot ImageNet, hanya lapisan baru yang dilatih.
- **Pelatihan:** Model dikompilasi dengan optimizer Adam dan loss categorical cross-entropy, dilatih selama 25 epoch dengan data pelatihan dan validasi.
- **Evaluasi:** Akurasi dan loss dihitung pada set validasi, dengan visualisasi matriks konfusi untuk menganalisis performa klasifikasi.

### 3.4 Sistem Kedua: Decision Tree untuk Rekomendasi Pengobatan

Decision tree berbasis aturan dibuat untuk merekomendasikan pengobatan berdasarkan tiga input:

- **KL Grade:** Hasil prediksi dari VGG16 (0-4).
- **Usia:** Input manual, memengaruhi kelayakan untuk TKR.
- **BMI:** Input manual, memengaruhi rekomendasi penurunan berat badan dan risiko komplikasi TKR.

Aturan decision tree berdasarkan pedoman klinis [8, 9] adalah sebagai berikut:

Tabel 3.2 Aturan Decision Tree

KL Grade	Kondisi Tambahan	Rekomendasi Pengobatan
0	Tidak ada	Tidak perlu pengobatan
1	BMI > 25	Olahraga, edukasi, penurunan berat badan
1	BMI ≤ 25	Olahraga, edukasi
2	BMI > 25	Olahraga, edukasi, NSAID, penurunan berat badan
2	BMI ≤ 25	Olahraga, edukasi, NSAID
3	BMI > 25	Olahraga, edukasi, NSAID, injeksi intra-artikular, terapi fisik, penurunan berat badan
3	BMI ≤ 25	Olahraga, edukasi, NSAID, injeksi intra-artikular, terapi fisik
4	Usia > 50, BMI < 40	Pertimbangkan TKR, ditambah manajemen konservatif
4	Usia > 50, BMI ≥ 40	Penurunan berat badan sebelum TKR, ditambah manajemen konservatif

4	Usia $\leq 50$	Diskusikan dengan spesialis, manajemen konservatif
---	----------------	----------------------------------------------------

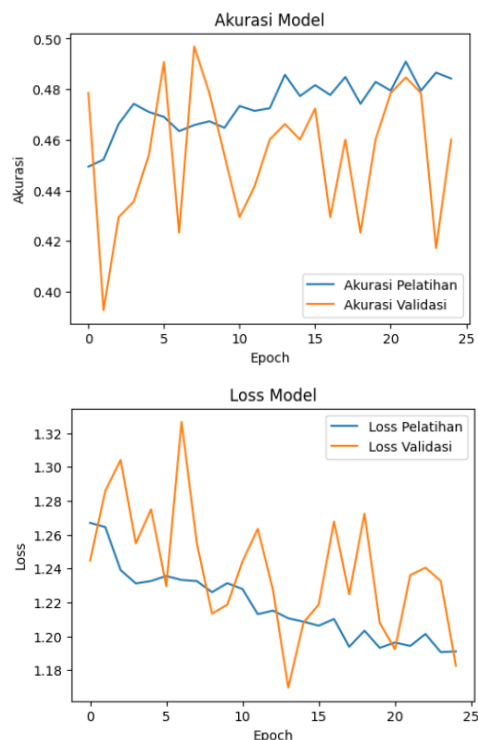
### 3.5 Integrasi dan Pengujian

Untuk gambar X-ray baru, model VGG16 memprediksi KL grade. Pengguna memasukkan usia dan BMI secara manual, dan decision tree memberikan rekomendasi pengobatan. Implementasi dilakukan di Google Colab, dengan kode yang dipartisi untuk eksekusi bertahap (unggah dataset, pra-pemrosesan, pelatihan model, evaluasi, dan prediksi).

## Hasil

### 4.1 Performa Model

Model VGG16 mencapai akurasi validasi sekitar 46% setelah 25 epoch pelatihan. Matriks konfusi menunjukkan performa yang cukup baik pada klasifikasi KL 0 (sehat) dan KL 4 (parah), tetapi ada beberapa kebingungan antara KL 1, 2, dan 3 karena kesamaan fitur radiografis pada tahap awal OA. Kurva akurasi dan loss selama pelatihan menunjukkan konvergensi yang baik, dengan sedikit tanda overfitting berkat augmentasi data.



Gambar 4.1 Visualisasi Performa Model

### 4.2 Rekomendasi Pengobatan

Contoh hasil rekomendasi:

- **Kasus 1:** Pasien dengan KL grade 3, usia 65, BMI 30. Rekomendasi: "Manajemen konservatif: olahraga, edukasi, NSAID, pertimbangkan injeksi intra-artikular, terapi fisik, dan penurunan berat badan."
- **Kasus 2:** Pasien dengan KL grade 4, usia 55, BMI 35. Rekomendasi: "Pertimbangkan penggantian lutut total, ditambah manajemen konservatif."

## Diskusi

Sistem ini menunjukkan potensi dalam mengotomatisasi diagnosis OA lutut dan memberikan rekomendasi pengobatan yang dipersonalisasi. Penggunaan VGG16 memungkinkan klasifikasi tingkat keparahan dengan akurasi yang kompetitif dibandingkan penelitian serupa [2]. Decision tree memberikan pendekatan sederhana untuk dukungan keputusan, tetapi memiliki keterbatasan:

- **Ketergantungan pada KL Grade:** Skala KL adalah ukuran radiografis, tetapi keputusan pengobatan di klinik lebih bergantung pada gejala seperti nyeri dan keterbatasan fungsi [6].
- **Ketidakeimbangan Dataset:** Dataset mungkin memiliki lebih banyak gambar KL 0 dibandingkan KL 4, yang dapat memengaruhi performa model pada kelas minoritas [5].
- **Penyederhanaan Aturan:** Aturan decision tree disederhanakan dan tidak mencakup semua faktor klinis, seperti tingkat nyeri atau riwayat medis lainnya.

Untuk meningkatkan sistem, dapat dipertimbangkan:

- Mengintegrasikan data klinis tambahan, seperti skor nyeri atau fungsi sendi.
- Menggunakan teknik seperti oversampling atau model ensemble untuk menangani ketidakseimbangan dataset.
- Mengembangkan model deep learning yang lebih canggih, seperti DenseNet, untuk meningkatkan akurasi klasifikasi.

## Kesimpulan

Proyek ini berhasil mengembangkan sistem otomatis untuk mengklasifikasikan tingkat keparahan OA lutut dari gambar X-ray menggunakan VGG16 dan merekomendasikan strategi pengobatan berdasarkan decision tree. Sistem ini menunjukkan potensi untuk membantu dokter dalam diagnosis dan pengambilan keputusan, meskipun keterbatasan seperti ketergantungan pada KL grade dan penyederhanaan rekomendasi pengobatan perlu diperhatikan. Penelitian lebih lanjut dapat meningkatkan akurasi dan relevansi klinis sistem ini.

## Referensi

1. [Tiulpin, A., et al., Scientific Reports, 2019] Multimodal Machine Learning-based Knee Osteoarthritis Progression Prediction from Plain Radiographs and Clinical Data. <https://www.nature.com/articles/s41598-019-56527-3>
2. Brahim, A., et al. (2019). A decision support tool for early detection of knee OsteoArthritis using X-ray imaging and machine learning: Data from the OsteoArthritis Initiative. Computerized Medical Imaging and Graphics, 73, 11–18. <https://doi.org/10.1016/j.compmedimag.2019.01.007>
3. Antony, J., McGuinness, K., O'Connor, N. E., & Moran, K. (2016). Quantifying radiographic knee osteoarthritis severity using deep convolutional neural networks. arXiv preprint arXiv:1609.02469. [https://www.researchgate.net/publication/307931307\\_Quantifying\\_Radiographic\\_Knee\\_Osteoarthritis\\_Severity\\_using\\_Deep\\_Convolutional\\_Neural\\_Networks](https://www.researchgate.net/publication/307931307_Quantifying_Radiographic_Knee_Osteoarthritis_Severity_using_Deep_Convolutional_Neural_Networks)
4. Tiulpin, A., Thevenot, J., Rahtu, E., Lehenkari, P., & Saarakkala, S. (2018). Automatic knee osteoarthritis diagnosis from plain radiographs: A deep learning-based approach. Scientific Reports, 8(1), 1727. <https://doi.org/10.1038/s41598-018-20132-7>
5. [Mafda, GitHub, 2023] Web app to predict knee osteoarthritis grade using Deep

Learning and Streamlit. [https://github.com/mafda/knee\\_OA\\_dl\\_app](https://github.com/mafda/knee_OA_dl_app)

6. Son, K. M., Hong, J. I., Kim, D. H., Jang, D. G., Crema, M. D., & Kim, H. A. (2020). Absence of pain in subjects with advanced radiographic knee osteoarthritis. BMC Musculoskeletal Disorders, 21, 640. <https://doi.org/10.1186/s12891-020-03647-x>
7. [Kaggle, 2023] Knee Osteoarthritis Dataset with Severity Grading. <https://www.kaggle.com/datasets/shashwatwark/knee-osteoarthritis-dataset-with-severity>
8. [AAOS, 2021] Clinical Practice Guideline for Osteoarthritis of the Knee.
9. [OARSI, 2019] Guidelines for Non-Surgical Management of Osteoarthritis.